

# 基于灰度共生矩阵的图形纹理检测及 路面状况的 SVM 分类实现

Author: anxu chen

2017/01/16

# 目录

1 引言.....	1
2 概念综述.....	1
2.1 纹理.....	1
2.2 纹理特征.....	1
2.3 纹理特征提取方法.....	1
2.4 灰度共生矩阵.....	1
3 设计原理.....	2
3.1 灰度共生矩阵形成过程.....	2
3.2 扫描方式.....	3
3.3 灰度共生矩阵的特征参数.....	3
3.3.1 二阶矩.....	4
3.3.2 对比度.....	4
3.3.3 相关性.....	4
3.3.4 熵.....	5
3.3.5 逆差距.....	5
3.4 灰度级数压缩.....	5
3.5 支持向量机（Support Vector Machine）.....	6
3.5.1 线性分类器.....	6
3.5.2 SVM 的数学基本描述.....	7
3.5.3 核函数.....	9
3.5.4 SVM 工作过程.....	10
3.6 系统建模.....	10
4 仿真结果分析.....	11
4.1 利用灰度共生矩阵特征值分析.....	11
4.2 SVM 分类结果.....	14
5 设计总结.....	16
参考文献.....	17

---

## 1 引言

图像的特征提取是图像的识别和分类、基于内容的图像检索、图像数据挖掘等研究内容的基础性工作，其中图像的纹理特征对描述图像内容具有重要意义，纹理特征提取已成为图像领域研究的一个重要方法。本文探讨了基于灰度共生矩阵(GLCM)的纹理特征提取方法，给出了基于 MATLAB 的简便实现代码，分析了共生矩阵各个构造参数对构造共生矩阵的影响。实现基于灰度共生矩阵(GLCM)的特定图像的纹理特征提取。

## 2 概念综述

### 2.1 纹理

纹理特征是一种重要的视觉线索，是图像中普遍存在、而又难以描述的特征。纹理作为物体表面的一种基本属性，广泛存在自然界中，是描述和识别物体的一种极为重要的特征。纹理分析技术一直是计算机视觉、图像处理、图像分析、图像检索等的重要应用。纹理分析的研究内容主要包括：纹理分类和分割、纹理合成、纹理检索和由纹理恢复形状等。这些研究内容的一个最基本的问题是纹理特征提取。

### 2.2 纹理特征

图像的纹理特征描述了在图像中反复出现的局部规律和像素排列规则，反映了宏观意义上灰度变化的一些规律，图像可以看成是不同纹理区域的组合，纹理是对局部区域像素之间关系的一种度量。纹理特征可用于定量描述图像中的信息。

### 2.3 纹理特征提取方法

纹理特征提取的主要方法有统计方法、模型方法、信号处理方法和结构方法。本文所用的是统计方法；统计方法是基于像元及其邻域的灰度属性，研究纹理区域中的统计特性。实践证明，灰度共生矩阵在统计方法中具有很旺盛的生命，用该方法提取的纹理特征具有很好的鉴别能力。

### 2.4 灰度共生矩阵

共生矩阵用两个位置像素的联合概率密度来定义，它不仅反映亮度的分布特性，也反映具有同样亮度或接近亮度的像素之间的位置分布特性，是有关图像亮度变化的二阶统计特征。它是定义一组纹理特征的基础。由于纹理是由灰度分布在空间位置上反复出现而形成的，因而在图像空间中相隔某距离的两像素之间会存在一定的灰度关系，即图像中灰度的空间相关特性。灰度共生矩阵就是一种通过研究灰度的空间相关特性来描述纹理的常用

方法。灰度直方图是对图像上单个像素具有某个灰度进行统计的结果，而灰度共生矩阵是对图像上保持某距离的两像素分别具有某灰度的状况进行统计得到的。

### 3 设计原理

#### 3.1 灰度共生矩阵形成过程

灰度矩阵被定义为从灰度为 $i$ 的原图像的点到原图像灰度为 $j$ 的点的概率， $i$ 、 $j$ 两点满足对应关系 $d = (Dx, Dy)$ ，灰度共生矩阵用 $P(i, j)(i, j = 0, 1, 2, \dots, L-1)$ 表示。其中 $L$ 表示图像的灰度级， $i$ 、 $j$ 分别表示像素的灰度。 $d$ 决定了图像中两个像素的位置关系。不同的 $d$ 决定了两个像素间的方向和距离。 $\theta$ 为灰度共生矩阵的生成方向，如图 3-1 所示：




图 3-1 灰度共生矩阵像素对关系

当两个像素间的位置关系 $d$ 选定后，就可以生成一定关系下的共生矩阵。

设图像为 $I(M, N)$ ，其中任意一点为 $A(x, y)$ 及偏离它的一点为 $B(x+dx, y+dy)$ ；设 $A$ 点对应的灰度值为 $I_i(x, y)$ ， $B$ 点对应的灰度值为 $I_j(x+dx, y+dy)$ 。假设点 $(x, y)$ 在整个图片中移动，会得到各种各样的 $(I_i, I_j)(0 \leq i, j \leq L-1)$ ，则 $(I_i, I_j)$ 的组合有 $L \times L$ 种。对于整个图片，统计出每一种 $(I_i, I_j)$ 值出现的次数，然后排列成一个矩阵，设 $G(I_i, I_j)$ 为每一种 $(I_i, I_j)$ 出现的次数，则所有情况的总次数：

$$Z = \sum_{i=0}^{L-1} \sum_{j=0}^{L-1} G(I_i, I_j) \quad (3-1)$$

假设 $P_{L \times L}$ 中每一个元素：

$$C(I_i, I_j) = \frac{G(I_i, I_j)}{Z} \quad (3-2)$$

那么  $P_{L \times L}$  则为灰度共生矩阵，且：

$$P_{L \times L} = \begin{bmatrix} C(I_0, I_0) & C(I_0, I_1) & \cdots & C(I_0, I_j) & \cdots & C(I_0, I_{L-1}) \\ C(I_1, I_0) & C(I_1, I_1) & \cdots & C(I_1, I_j) & \cdots & C(I_1, I_{L-1}) \\ \cdots & \cdots & \cdots & \cdots & \cdots & \cdots \\ C(I_i, I_0) & C(I_i, I_1) & \cdots & C(I_i, I_j) & \cdots & C(I_i, I_{L-1}) \\ \cdots & \cdots & \cdots & \cdots & \cdots & \cdots \\ C(I_{L-1}, I_0) & C(I_{L-1}, I_1) & \cdots & C(I_{L-1}, I_j) & \cdots & C(I_{L-1}, I_{L-1}) \end{bmatrix} \quad (3-3)$$

共生矩阵的每一个元素代表了一种灰度组合下出现的概率。如元素  $P(1,0)$  代表了图像上位置关系为  $d$  的两个像素灰度分别为 1 和 0 的情况出现概率。

### 3.2 扫描方式

对于纹理特征图像的提取，我们需要对灰度共生矩阵的计算结果作适当处理。最简单的方法是取不同方向 ( $0^\circ, 45^\circ, 90^\circ, 135^\circ$ ) 的偏移参数，对灰度共生矩阵分别求取其特征参数，然后对这些特征指标计算其均值和方差。这样处理就抑制了方向分量，使得到的纹理特征与方向无关。对 3.1 中提到的  $d = (Dx, Dy)$  来说：

当  $Dx=0, Dy=1$  时，像素对是水平的，即  $0^\circ$  扫描；

当  $Dx=1, Dy=1$  时，像素对是左斜的，即  $45^\circ$  扫描；

当  $Dx=1, Dy=0$  时，像素对是竖直的，即  $90^\circ$  扫描；

当  $Dx=1, Dy=-1$  时，像素对是右斜的，即  $135^\circ$  扫描。

### 3.3 灰度共生矩阵的特征参数

灰度共生矩阵反映的是图像灰度关于方向、相邻间隔、变化幅度的综合信息。通过灰度共生矩阵可以分析图像的局部特征式和排列规则等，为了能更直观地以灰度共生矩阵描述纹理状况，一般不直接应用得到的共生矩阵，而是在其基础上获取二次统计量。Haralick 等人定义了 14 个用于纹理分析的灰度共生矩阵特征参数：二阶矩、对比度、相关性、差分矩、逆差分矩（均与性）、和平均、和方差、和熵、熵、差方差、差熵、相关测度 1、相关测度 2、最大相关系数。Ulaby 等人研究发现：在基于 GLCM 的 14 个纹理特征中，仅有 4 个特征参数是不相关的，这 4 个特征既便于计算又能给出较高的分类精度，一般采用二阶

矩（能量）、对比度、相关性、熵。四个最常用的特征来提取图像的纹理特征，本文补充一个参数逆差分矩来作为描述特征参数。

### 3.3.1 二阶矩

二阶矩是灰度共生矩阵元素值的平方和，所以也称能量，反映了图像灰度分布均匀程度和纹理粗细度。如果共生矩阵的所有值均相等，则  $E$  值小；相反，如果其中一些值大而其它值小，则  $E$  值大。 $E$  值大表明一种较均匀和规则变化的纹理模式，图片纹理较粗；反之， $E$  值小表明一种较散乱和不规则变化的纹理模式，图片纹理较细。其计算公式为：

$$E = \sum_{i=0}^{L-1} \sum_{j=0}^{L-1} P^2(i, j) \quad (3-4)$$

### 3.3.2 对比度

对比度反映了图像的清晰度和纹理沟纹深浅的程度。纹理的沟纹深，其对比度大，效果清晰；反之，对比度小，则沟纹浅，效果模糊。灰度差即对比度大的像素对越多，这个值越大。灰度共生矩阵中远离对角线的元素值越大，对比度越大。其计算公式为：

$$C = \sum_{t=0}^{N-1} t^2 \left\{ \sum_{i=0}^{L-1} \sum_{j=0}^{L-1} P^2(i, j) \right\} \quad (3-5)$$

其中  $t = |i - j|$ 。

### 3.3.3 相关性

相关性度量灰度共生矩阵元素在行或列方向上的相似程度。因此，相关值大小反映了图像中局部灰度相关性。当矩阵元素值均匀相等时，相关值就大；相反，如果矩阵像元值相差很大则相关值小。也就是说，如果图像中有水平方向纹理，则在水平方向矩阵的相关值大于其余方向矩阵的相关值。其计算公式为：

$$R = \frac{1}{\sigma_1 \sigma_2} \left\{ \sum_{i=0}^{L-1} \sum_{j=0}^{L-1} ij P(i, j) - \mu_1 \mu_2 \right\} \quad (3-6)$$

其中：

$$\mu_1 = \sum_{i=0}^{L-1} i \sum_{j=0}^{L-1} P(i, j) \quad (3-7)$$

$$\mu_2 = \sum_{j=0}^{L-1} j \sum_{i=0}^{L-1} P(i, j) \quad (3-8)$$

$$\sigma_1 = \sqrt{\sum_{i=0}^{L-1} (\mu_1 - i)^2 \sum_{j=0}^{L-1} P(i, j)} \quad (3-9)$$

$$\sigma_2 = \sqrt{\sum_{j=0}^{L-1} (\mu_2 - j)^2 \sum_{i=0}^{L-1} P(i, j)} \quad (3-10)$$

### 3.3.4 熵

熵是图像所具有信息量的度量，纹理信息也属于图像的信息，是一个随机性的度量，当灰度共生矩阵中所有元素有最大的随机性、灰度共生矩阵中所有值几乎相等时，共生矩阵中元素分散分布时，熵较大。它表示图像中纹理的非均匀程度或复杂程度。若图像没有任何纹理，则灰度共生矩阵几乎为零阵。它反映图像中纹理的复杂程度或非均匀度。若纹理复杂，熵值大；反之，若图像中灰度均匀，共生矩阵中元素大小差异大，熵值小。它表示了图像中纹理的非均匀程度或复杂程度。其计算公式为：

$$En = -\sum_{i=0}^{L-1} \sum_{j=0}^{L-1} P(i, j) \log P(i, j) \quad (3-11)$$

### 3.3.5 逆差距

逆差距反映图像纹理的同质性，度量图像纹理局部变化的多少。其值大则说明图像纹理的不同区域间缺少变化，局部非常均匀。其计算公式为：

$$D = \sum_{i=0}^{L-1} \sum_{j=0}^{L-1} P(i, j) \frac{1}{1 + (i - j)^2} \quad (3-12)$$

## 3.4 灰度级数压缩

计算纹理特征的第一步就是将多波段的影 RGB 影像转换为灰度图像，在实际应用中，一幅灰度影像的灰度级一般为 256 级，在计算由灰度共生矩阵得出的纹理特征时，要求影像的灰度级远小于 256，主要是因为图像的灰度共生矩阵的计算量由图像的灰度等级和图像的大小来确定。例如：假定图像  $I$  有  $L$  个灰度级，图像大小为行  $M$ 、 $N$  列，则运算量大约是  $M \times N \times L$ ，按一般情况  $M = 512, N = 512, L = 256$  来计算，其基本运算至少要  $1.718 \times 10^{10}$  次。以现行微机的运算速度每秒 2 亿次为例，对上述一幅图像计算其灰度共生矩阵至少需要 85 秒以上。由此可见，这样长的时间用来进行图像的识别是不太切合实际的。解决的办法是：在尽量保持图像原形的情况下大量削减图像灰度级的取值个数和图像分辨率。因此，在计算灰度共生矩阵时，在不影响纹理特征的前提下往往先将原图像的灰度级压缩到较小

的范围，本文用 16 级，以便减小共生矩阵的尺寸。

由于灰度通常分布在较窄的范围内，若直接把灰度除以 16 取整，会引起图像的清晰度降低。所以在对图像进行灰度级压缩时，首先需将图像进行直方图均衡化处理，增加灰度值的动态范围，从而增加影像的整体对比效果。

这样进行了直方图均衡化之后，再将灰度除以 16 取整，便可以将 0~255 灰度级变换为 0~15，所以影像颜色显得很暗淡，但是在进行纹理信息处理时对纹理特征的影响不大。如图 3-1 所示，直方图均衡化前后的效果对比。



3-1 直方图均衡化前后的效果

### 3.5 支持向量机 (Support Vector Machine)


支持向量机(support vector machine)是一种分类算法，通过寻求结构化风险最小来提高学习机泛化能力，从而达到在统计样本量较少的情况下，亦能获得良好统计规律的目的。通俗来讲，它是一种二类分类模型，其基本模型定义为特征空间上的间隔最大的线性分类器，即支持向量机的学习策略便是间隔最大化，最终可转化为二次规划问题的求解。

SVM 是一个二分类的分类模型，或者说叫做分类器，可以区分两类样本，它的思想是：给定一个包含正例和反例的样本集合，SVM 的目的是寻求一个超平面对正例和反例进行分割。

#### 3.5.1 线性分类器

如果一个线性函数能够将样本完全正确的区分，那么这些样本是线性可分的，否则称为非线性可分。对于线性函数来说，在一维空间就是一个点，在二维空间就是一条直线，三维空间里就是一个平面。依此类推，在高维空间里就也就是上文所说的超平面 (Hyper Plane)，如图 3-2 所示，这是一个二维的超平面。





3-2 二维超平面

在样本空间中，划分超平面可通过下面的线性方程来描述：

$$g(x) = w^T x + b \quad (3-13)$$

其中  $x$  是分类样本， $w^T$  和  $b$  是分类函数的两个参数，假设已经完成对样本的分类，且两种样本的标签假设为  $\{-1, +1\}$ ，那么对于一个分类器来说， $g(x) > 0$  和  $g(x) < 0$  就可以分别代表两个不同的类别； $-1$  和  $+1$ 。

### 3.5.2 SVM 的数学基本描述

如上面所述，对于分类器的形成有了一个背景的介绍。但是只能把样本分开是不够的，SVM 的核心思想是使分开的两个类别有最大的间隔，这样才使分隔具有更高的可信度，并且对未知的新样本有很好的分类预测作用。对于如何描述最大间隔，SVM 的方案是：让离分隔面最近的数据点有最大的距离。为了描述离分隔面最近的数据点，需要找到两个和这个超平面平行且距离相等的超平面  $H_1$  和  $H_2$ ：

$$\begin{cases} H_1 : w^T x + b = +1 \\ H_2 : w^T x + b = -1 \end{cases} \quad (3-14)$$

如图 3-3 所示：




图 3-3 超平面的确定

$H_1$  和  $H_2$  这两个超平面的上的点就是理论上离分隔超平面最近的点，是他们的存在决定了  $H_1$  和  $H_2$  的位置，支撑起了分隔面，他们就是所谓的支持向量，这就是支持向量机的由来。有了这两个超平面就可以顺理成章的定义上面提到的间隔了。

已知，二维情况下  $ax+b=c_1$  和  $ax+b=c_2$  的距离公式为：

$$m = \frac{|c_1 - c_2|}{\sqrt{a^2 + b^2}} \quad (3-15)$$

可以推出  $H_1$  和  $H_2$  两个超平面的间隔为  $m = \frac{2}{\|w\|}$ ，即现在的目的是要最大化这个间隔。

所以支持向量机又叫最大间隔超平面分类器，这也就把问题转化为求最小  $\|w\|$ ，为了之后的

的求导和计算方便，进一步等价求最小  $\frac{1}{2}\|w\|^2$ ，假设超平面能将样本分类正确，则可令：

$$\begin{cases} w^T x_i + b \geq +1, y_i = +1 \\ w^T x_i + b \leq -1, y_i = -1 \end{cases} \quad (3-16)$$

两个式子综合一下有：

$$y_i(w^T x_i + b) \geq 1 \quad (3-17)$$

这就是目标函数的约束条件。现在问题就变成了一个求最优解的问题：

$$\begin{cases} \text{条件: } y_i(w^T x_i + b) \geq 1 \\ \text{目标函数: } \min((\frac{1}{2}\|w\|^2)) \end{cases} \quad (3-18)$$

这是一个二元函数求极值问题，可以利用拉格朗日定理求出最优解。在本文不做进一步的叙述。由这个式子可以解出  $w = \sum_{i=1}^n \alpha_i y_i x_i$ 。所以：

$$g(x) = (\sum_{i=1}^n \alpha_i y_i x_i)^T x + b = \sum_{i=1}^n \alpha_i y_i \langle x_i, x \rangle + b \quad (3-19)$$

这个式子表示：对  $x$  的预测只要求它与训练点  $x_i$  的内积，这是用 **kernal** 进行线性推广的基本前提。并且并不是每个训练点都要用到，只需要用到支持向量，非支持向量的系数  $\alpha$  为 0。 $\langle x_i, x \rangle$  表示内积运算。

### 3.5.3 核函数

前面的方法对于线性可分的样本来说是可行的，但是对线性不可分的样本却无能为力。如果可以把一个低维线性不可分的样本集映射到高维，使其变成线性可分的，这样就能够使用 **SVM** 使其工作了。设映射函数为  $\Phi(\bullet)$ ，则映射后的空间分类函数变为：

$$f(x) = \sum_{i=1}^n \alpha_i y_i \langle \Phi(x_i), \Phi(x) \rangle + b \quad (3-20)$$

但是，如果拿到低维数据直接映射到高维的话，维度的数目会呈现爆炸性增长。所以这里需要引入核函数（**kernal function**）。核函数的思想是寻找一个函数，这个函数使得低维空间中进行运算的结果和映射到高维空间中计算内积  $\langle \Phi(x_i), \Phi(x) \rangle$  的结果相同，这样就避开在高维空间中进行计算，而最后的结果却是等价的。现在，分类函数就变成了：

$$f(x) = \sum_{i=1}^n \alpha_i y_i \langle K(x_i), K(x) \rangle + b \quad (3-21)$$

其中， $K(\bullet)$  就是核函数。

由于对任意数据集找到它合适的映射比较困难且没有必要，所以通常从常用的核函

数中选择。例如：多项式核函数，高斯核函数，线性核函数，字符串核函数。此时引入  $Sgn(x)$  函数便可实现分类，设  $C(x)$  为分类结果，则有：

$$C(x) = Sgn(f(x)) \quad (3-22)$$

### 3.5.4 SVM 工作过程

有了上面的讨论，那么分类过程的理解是比较容易的，整个执行过程如图 3-4 所示：

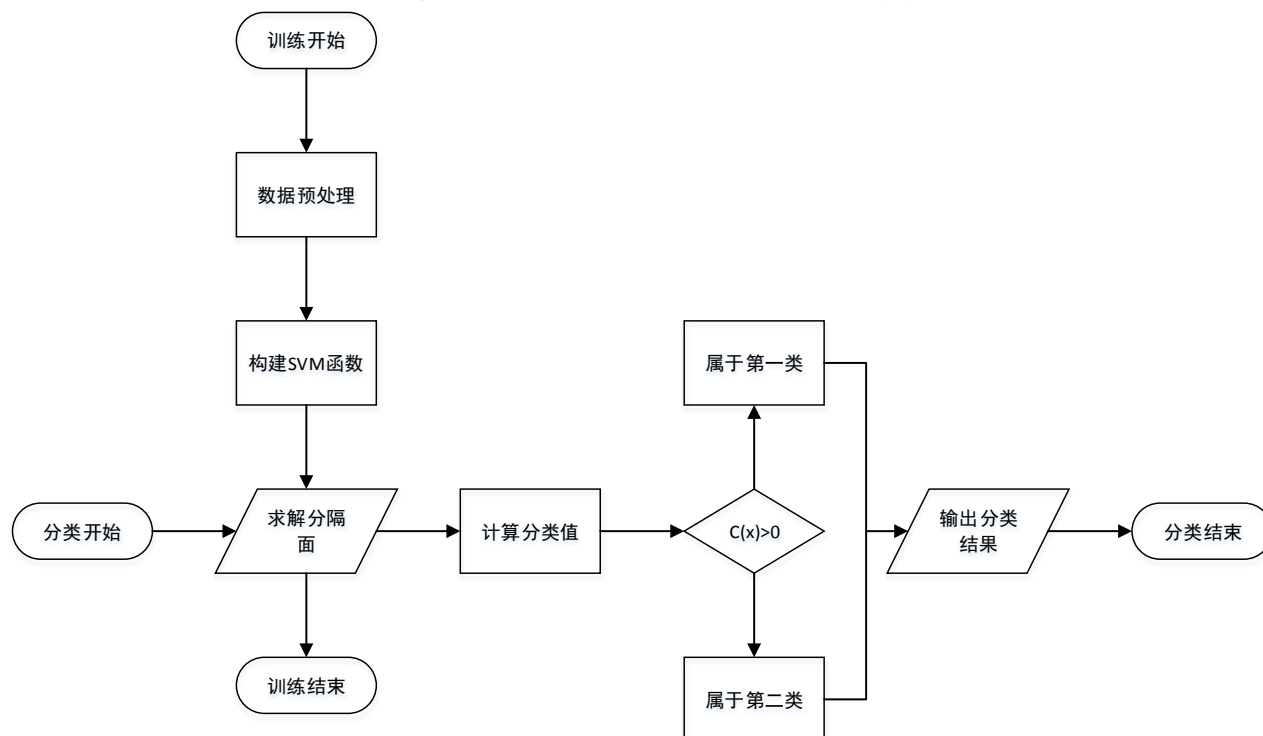


图 3-4 SVM 分类过程

## 3.6 系统建模

本文以识别路况为背景设计系统，首先读取图像文件，在为了得到较为理想的结果，给出的图片尺寸较小，这样的目的在于提高运行速度、能够对理想情况下的识别结果有更加精确的把握。由于 RGB 图像的体积较大，但另一方面我们也知道，一张图片也可以用其灰度图像来反映，因此，对目标图像进行灰度的转化，可以降低对设计复杂度和运行效率的要求。尽管灰度转化后可以有效的降低图片的大小，但是对于 256 灰度级的图片仍然会给处理带来一些时间上的消耗，因此需要在保持原图像信息不变的情况下大量削减灰度级，通过对图像进行直方图均衡化处理，增加灰度值的动态范围，从而增加图像的整体对比效果。通常，需要将每个扫描的方向所计算的特征参数计算出来作一个权衡，这样能够更好地综合影响因素，一般会将每个方向的特征参数计算出来取平均，这样就可以以一个综合的指标来识别图像了。把所有的设计思路综合起来，可以用图 3-5 所示的系统设计框图来

反映。

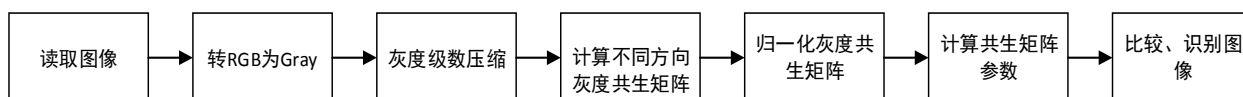


图 3-5 系统设计框图

对于道路状况的预测，在本文所做的试验中，选取了安全路面和非安全路面作为分类器训练样本，共 42 个样本，安全路面和非安全路面样本数各一半，利用图 3-5 的系统计算出的特征值作为训练样本，求解分类器，进而实现对未知路面进行识别。

## 4 仿真结果分析

### 4.1 利用灰度共生矩阵特征值分析

灰度共生矩阵具有丰富的特征参数，能从不同的角度对纹理进行细致的刻画。本文以四种路面情况为处理的对象，如图 4-1 所示：



图 4-1 四种路况原图

应用 MATLAB 进行编程，首先是计算四个方向上的灰度共生矩阵，取像素间的距离为 1；其次由灰度共生矩阵计算所需的五个纹理特征量，获取四种路面的灰度共生矩阵的五个特征参数。灰度共生矩阵的方向取四个方向。

通过下文可以看出，不同类型的路面纹理特征参数具有明显的差异，由于这些参量表示了图像纹理特征某一方面的性质，因此可以通过比较这些参量反映出不同图像纹理特征的差异，在不同参量的差异的对比中，可以得出对路面纹理进行分类识别应当是可行的，

从而达到实现对不同路面状况的分类的目的。




图 4-2 逆差

从图 4-2 不仅可以看出每种路面的区分明显，而且发现雨天路面的逆差是最大的，从原始图像也能看出雨天图像纹理的不同区域间缺少变化，局部非常均匀。故其灰度共生矩阵的逆差值大。另一方面，若求出每一种路面图像的灰度共生矩阵的逆差平均值，也可以对每一种图片有一个很好区分。也就是说，对于这四张图片的识别而言，利用逆差就能对他们进行分类。




图 4-3 能量

如图 4-3 所示，曲线代表每中路面的二阶距特征，其值越大，说明纹理均匀，能量越大。图中分别代表雪天路面和泥泞路面的两条曲线的距离相差很大，雪天路面所代表曲线的值比代表泥泞路面大曲线整体上大得多，说明雪天路面的纹理比泥泞路面的纹理均匀，能量也大，这样我们可以通过二阶距就能区别这两种路面的种类。然而，代表雨天路面曲

线和安全路面曲线却相互重叠、交叉，不容易分辨，此时，可以通过比较图 4-2 中的曲线差异进行辅助区别，这样也能区分四种路况。




图 4-4 相关度

如图 4-4 所示，图中每条曲线代表不同路面的相关度特征，它度量空间灰度共生矩阵元素在行或列方向上的相似程度，因此，相关值大小反映了图像中局部灰度相关性。如果图像中有水平方向纹理，则水平方向矩阵的相关度大于其余矩阵的相关度值。从图中每个角度对应的相关值可以看出，在  $45^\circ$  方向上雨天路面对应的的相关值比雪天路面的相关值大，而且，雨天路面和雪天路面与泥泞路面和安全路面对应的值相差很大，这样就可以通过这种巨大的差异把路面分成两类；雨天路面和雪天路面、泥泞路面和安全路面。有助于综合其他参量从而对路面情况分类有更好的把握。




图 4-5 对比度



对比度反映了图像的清晰度和纹理沟纹深浅的程度。纹理的沟纹深，其对比度大，效果清晰；反之，对比度小，则沟纹浅，效果模糊。如图 4-5 所示，雪天和雨天的清晰度高，因此其对比度也很大，但直接从得出的曲线里面不能够对每种路况有很好的区分，只可以对路况的识别有一个大致的把握，需要结合其他的分析曲线才能够更好的区分。在路况的识别中，对比度的识别作用有所减弱。




图 4-6 熵

熵是图像所具有信息量的度量，它反映图像中纹理的复杂程度或非均匀度。若纹理复杂，熵值大；反之，若图像中灰度均匀，共生矩阵中元素大小差异大，熵值小。它表示了图像中纹理的非均匀程度或复杂程度。这样看出，安全路面和泥泞路面的熵值偏高，说明其图像中的灰度差异较大，而雨天路面和雪天路面的熵值比较少，说明其图像中的灰度差异较小。但是由曲线可以看出，曲线有交叠或相隔较近，这样对于区分路况来说是不利的，因此，仍然需要结合其他的参数才能用有更好的识别意义。

## 4.2 SVM 分类结果

在本设计中，以 42 张道路状况图片的能量和对比度作为样本属性，利用 Matlab 中自带的 `svmtrain()` 函数训练得到一个分类器。但是 Matlab 中自带的 `svmtrain()` 函数只能进行二分类，因此，对输入的样本做一定的处理；在前面的论述中都是以四种道路状况进行分类的，但有时我们只关心道路状况的好与坏，故将道路状况图片分为安全路面和非安全路面两类，这样就可以进行二分类了。然后利用一组图片：4 张安全道路和 4 张非安全道路图片，作为分类对象放入 `svmclassify()` 函数进行分类，这就完成了对道路状况的分类。

经过多次实验的对比，对于本设计来说，`svmtrain()` 函数在使用 3 阶多项式作为核函数时达到的分类效果最好。故选定 3 阶多项式作为核函数作为分类器所使用的参数，通过实



验可以得到如下分类器：




图 4-7 分类函数分类效果

从图 4-7 中可以看出，并没有达到对样本的完全分类，引起这种现象的原因是多方面的，主要原因是核函数的选取和样本的选取，这两者在分类器的训练中有明显的作用。尽管如此，从图中依旧可以看出，对两个类别的分类仍然比较理想，作为实验模型，不再做进一步的优化。

将需要分类的目标放入分类器中进行分类。得到如图 4-8 的结果：




图 4-8 分类结果

通过样本标签和分类后的标签对比，得出使用能量和对比度作为训练分类器的样本，分类器对于实验待分类样本分类的其正确率为：95%，由此可以看出，这个分类器对于道路状况的分类仍然具有一定的意义。

---

## 5 设计总结

- (1) 计算灰度共生矩阵时要考虑三个变量，图像灰度级  $L$  方向  $\theta$  和距离  $d$ 。
- (2) 对于灰度级  $L$  的选取，灰度级决定了灰度共生矩阵的计算规模，降低灰度级可以提高计算速度和减少存储空间需求，且适当降低灰度级还可以减少噪声对图像的影响，但过小的灰度级会破坏有用纹理的成分。
- (3) 对于距离  $d$  的选择，共生矩阵在精细纹理中随距离而快速变化，而在粗糙纹理中随距离则变化缓慢。一般而言，对于平滑纹理用较大的距离，对于粗糙纹理用较小的距离会取得较好的效果。对于方向  $\theta$  的选择，一般有四种取值 ( $0^\circ, 45^\circ, 90^\circ, 135^\circ$ ) 通过不同  $\theta$  可以考察不同的纹理，不同  $\theta$  生成的共生矩阵中包含不同的纹理信息。一般而言，在考虑方向时，往往是分别计算四个方向灰度共生矩阵所确定的纹理特征值，然后以各方向特征值的均值作为最终纹理分量。
- (4) 利用 SVM 进行分类时，样本的选取和核函数的选取是分类器是否优良的一个重要影响因素，因此，对于一个优良的分类器，应该充分考虑各种影响因素后，选择一个最优的方案才能使待分类目标得到更好的分类。

---

## 参考文献

- [1] 焦蓬蓬,郭依正,刘丽娟,卫星.灰度共生矩阵纹理特征提取的 Matlab 实现.计算机技术与发展.2012.11 .
- [2] 高程程,惠晓威.基于灰度共生矩阵的纹理特征提取.计算机系统应用.2010.06.
- [3] 李智峰,朱谷昌,董泰锋.基于灰度共生矩阵的图像纹理特征地物分类应用.地质与勘测.2011.05.
- [4] 冯建辉,杨玉静.基于灰度共生矩阵提取纹理特征图像的研究.北京测绘.2007.09
- [5] 傅文杰,林明森.利用SVM与灰度共生矩阵从QuickBird影像中提取枇杷信息.国家卫星海洋应用中心.20010.05